

# 8244

*by Jtiik Jtiik*

---

**Submission date:** 11-Jan-2024 01:47PM (UTC+0700)

**Submission ID:** 2269268522

**File name:** JTIK-SyahroniWahyuIriananda.docx (353.15K)

**Word count:** 4609

**Character count:** 29048

## Optimasi Klasifikasi Sentimen Komentar Pengguna Game Bergerak Menggunakan SVM, Grid Search dan Kombinasi N-Gram

1  
Syahroni Wahyu Iriananda<sup>\*1</sup>, Renaldi Widi Budiawan<sup>2</sup>, Aviv Yuniar Rahman<sup>3</sup>, Istiadi<sup>4</sup>

16  
1, 2, 3, 4 Teknik Informatika, Fakultas Teknik, Universitas Widya Gama Malang  
Email: <sup>1</sup>syahroni@widyagama.ac.id

\*Penulis Korespondensi

(Naskah masuk: dd mmm yyyy, diterima untuk diterbitkan: dd mmm yyyy)

### Abstrak

1  
Game online menjadi budaya dalam industri yang berkembang pesat. Pengguna atau pengembang game menggunakan analisis sentimen untuk mengetahui ulasan pemain game sehingga dapat menetapkan arah pengembangan dan peningkatan pada game tersebut. Penelitian ini mengklasifikasikan sentimen menggunakan Support Vector Machine (SVM) dan fitur seleksi N-Gram, teknik Grid Search (GS) untuk optimalisasi *hyperparameter* guna mendapatkan akurasi optimum. Untuk mengetahui dampak metode tersebut, penelitian ini melakukan pengujian dengan berbagai skenario jumlah baris data, pemilihan *hyperparameter*, rasio data latih dan data uji dan skenario penggunaan N-Gram. Model tersebut dievaluasi menggunakan Akurasi, *Precision*, *Recall*, dan Area dibawah kurva ROC (AUC). Hasil pengujian tersebut menunjukkan bahwa dengan menggunakan 3600 baris data dari dataset gabungan (Allgame), fitur seleksi N-Gram kombinasi Unigram, Bigram, dan Trigram (UniBiTri), dan nilai kfold=10 untuk *cross-validation* dan menggunakan kernel Radial Basis Function (RBF) menghasilkan kinerja dalam mengklasifikasi ulasan pengguna dengan akurasi 87,3%, *precision* 88,5%, *recall* 85,5% and AUC 0,9081.

**Kata kunci:** Optimasi, Sentimen, Game Bergerak, SVM, N-Gram, Grid Search

## OPTIMIZING SENTIMENT CLASSIFICATION OF MOBILE GAME USER REVIEWS USING SVM, GRID SEARCH AND N-GRAM COMBINATIONS

### Abstract

Online gaming is becoming a culture in a rapidly growing industry. Game users or game developers can employ sentiment analysis to discover the player opinions or review that they can determine game development and improvement direction. In this study, the researchers classified sentiment using the Support Vector Machine (SVM) algorithm and use N-Gram as feature selection. Grid Search (GS) for *hyperparameter* optimization to obtain optimum accuracy. To find out the impact of these method, the researcher conducted an investigation using various test scenarios of number of data lines, *hyperparameter* selection, train and test dataset ratio, and N-Gram utilization scenario. The classifier model performance evaluated using Accuracy, Precision, Recall and Area Under ROC Curve (AUC). The results shows that, by using 3600 rows of combined dataset (Allgame), the combination of Unigram, Bigram, and Trigram (UniBiTri) N-Gram selection features, and kfold=10 for *cross-validation*, and Radial Basis Function (RBF) kernel produce a pretty good performance in classifying user review accuracy is 87.3%, precision 88.5%, recall 85.5% and AUC 0.9081.

**Keywords:** Optimization, Sentiment, Mobile Game, SVM, N-Gram, Grid Search

### 1. PENDAHULUAN

Pada masa pandemi COVID-19 yang lalu salah satu cara beberapa orang menghibur diri mereka yaitu bermain *Mobile game* secara online bersama teman mereka ataupun dengan orang asing (King *et al.*, 2020). hiburan yang menyenangkan bagi orang-orang di rumah yang mencari interaksi sosial secara daring, dan statistik menunjukkan bahwa waktu bermain dan penjualan game telah meningkat secara dramatis sejak kebijakan *lock-down* dimulai (King *et*

*al.*, 2020). Sebelum mereka mengunduh dan memasang Mobile game pada perangkat mereka, biasanya mereka memeriksa ulasan atau *review* dan peringkat game terlebih dahulu (Hendriyanto, Ridha and Enri, 2022).

Analisis sentimen memiliki peran yang penting baik bagi pengguna maupun pengembang aplikasi game. Melalui evaluasi opini dan ulasan yang disampaikan oleh para pengguna yang telah mencoba permainan tersebut, pengembang mampu

memperoleh wawasan yang berharga. Informasi ini menjadi landasan untuk menentukan arah pengembangan dan perbaikan game. Dengan demikian, analisis sentimen membantu para pengembang mengidentifikasi aspek-aspek yang perlu ditingkatkan dalam game dan juga fitur-fitur yang paling dihargai oleh pengguna. Dengan pendekatan ini, pengembang game dapat membuat keputusan berdasarkan data, dengan tujuan meningkatkan kualitas game dan memenuhi ekspektasi pengguna secara lebih efektif. Selain itu, mereka dapat menentukan arah pengembangan dan perbaikan pada game tersebut. (Kusnadi *et al.*, 2021). Analisis sentimen ini dapat digunakan untuk aspek individual game seperti gameplay, cerita, grafik, dan lainnya. Hal ini dapat mempertimbangkan ulasan kritikus, konsumen, dan pemberi pengaruh (*influencer*) untuk memberikan pandangan secara menyeluruh tentang opini industri.

Dalam proses klasifikasi sentimen, peneliti sering menggunakan algoritma Support Vector Machine (SVM). Algoritma ini cocok digunakan untuk klasifikasi data teks yang memiliki sifat dasar teks yang cenderung mempunyai dimensi yang tinggi (Hendriyanto, Ridha and Enri, 2022). Algoritma SVM efektif dan stabil di ruang dimensi tinggi. Ini mampu mencapai tingkat akurasi yang tinggi dan lebih mudah dilatih dibandingkan dengan beberapa algoritma pembelajaran mesin lainnya. Selain itu, penggunaan memori lebih efisien karena keunggulan pemetaan kernel ke dalam ruang fitur dimensi tinggi. (Birjali, Kasri and Beni-Hssane, 2021).

Tantangan terbesar yang dihadapi adalah bagaimana memilih fungsi kernel dan nilai parameter SVM. Pengaturan parameter yang tidak tepat menyebabkan hasil klasifikasi yang buruk. Maka dari itu penyetelan *hyperparameter* adalah pilihan terbaik untuk mencapai parameter pembelajaran mesin yang optimal (Prabu *et al.*, 2022). Optimalisasi *hyperparameter* dapat membutuhkan waktu yang sangat lama jika dilakukan secara manual, terutama ketika algoritma pembelajaran memiliki banyak parameter (Khalid and Javaid, 2020). Metode yang sering digunakan untuk memilih *hyperparameter* yang populer diantaranya adalah *Grid Search (GS)* yang menggunakan mekanisme *Cross Validation (CV)* dalam proses pengujian setiap parameter model tanpa harus melakukan validasi manual satu per satu (Nugraha and Sasongko, 2022). Fungsi kernel digunakan untuk mentransformasi data ke ruang dimensi yang lebih tinggi, dan disebut ruang kernel, berguna untuk memisahkan data secara linear. Dalam ruang berdimensi tinggi ini dilakukan tahapan transformasi fitur (*feature selection*) untuk meningkatkan hasil klasifikasi yang lebih akurat dengan N-Gram yang diterapkan dengan melakukan modifikasi pemisahan atau pemecahan berdasarkan kata (Arifin, Enri and Sulistiyowati, 2021). N-Gram berpengaruh terhadap akurasi model. Dalam kajian (Pujadayanti, Fauzi and Sari, 2018) menggunakan

metode klasifikasi Naïve Bayes dan N-gram menerapkan *full preprocessing* dan kombinasi N-Gram menghasilkan akurasi yang lebih baik sebesar 97% tahap pengujian.

Beberapa penelitian terdahulu yang terkait dengan penelitian ini disajikan pada Tabel 1. Kajian terkait game dilakukan oleh (Abimanyu *et al.*, 2022) terhadap *games online* Apex Legends dari sosial media Twitter menggunakan VADER menghasilkan sentimen positif sebesar 18%, negatif 4,8%, dan neutral sebesar 77,2%, dengan nilai akurasi sebesar 65,2% dari 500 data uji. Sementara itu (Febrianta, Widiyanesti and Ramadhan, 2021) melakukan klasifikasi game indie pada Steam dengan Naïve Bayes dan pemodelan topik berbasis *Latent Dirichlet Allocation (LDA)* memiliki akurasi 75,45%.

Penelitian terkait algoritma Naïve Bayes (NB) dilakukan oleh (Sidiq, Dermawan and Umaidah, 2020) pada dataset *Group Facebook komunitas game Arena of Valor (AoV)* menghasilkan akurasi sebesar 75%, precision sebesar 63%, recall sebesar 67%, dan F-measure sebesar 64%.

Tabel 1. Komparasi Model Klasifikasi Sentimen

Author	Obyek	Metode
(Arifin, Enri and Sulistiyowati, 2021)	Artikel Ilmiah, Syntax Jurnal Informatika	SVM, Linear, RBF, Polynomial, Sigmoid, TFIDF, N-Gram
(Abimanyu <i>et al.</i> , 2022)	Twitter, Apex Legends	VADER
(Febrianta, Widiyanesti and Ramadhan, 2021)	Game Indie, Steam	Naïve Bayes dan Model LDA
(Sidiq, Dermawan and Umaidah, 2020)	Facebook Group AoV	Naïve Bayes
(Pratanto <i>et al.</i> , 2020)	Google Playstore Review	Naïve Bayes
(Fide, Suparti and Sudarno, 2021)	Tiktok, Google Playstore	SVM
(Sujadi, 2022)	Google Play Store Review, Online Shop	SVM
(Pamungkas and Kharisudin, 2021)	Twitter, COVID-19	SVM, NB, KNN
(Liang, 2021)	Twitter, Ujaran Kebencian,	SVM, XGBoost, dan Neural Network
(Rahman, Utami and Sudarmawan, 2021)	Google Play Store Review, Shopee, Ruanggunu, Tokopedia, Gojek	NB dan GA, Cross Validation
(Iriananda, Putra and Nugroho, 2021)	Google Play Store Review, Bahasa Indonesia, Marketplace	SVM, Kernel Linear, RBF, Polynomial, Decision Tree (DT), RF, LR
(Thenata, 2021)	Twitter, Instagram, Facebook, Bahasa Indonesia	KNN, SVM, NB

Penelitian yang menggunakan ulasan aplikasi Google Apps (Pratanto *et al.*, 2020) Menggunakan 200 data review *E-marketplace* populer di Google Playstore, menghasilkan nilai akurasi NB 96,667%. Kajian (Fide, Suparti and Sudarmo, 2021) menganalisa review aplikasi Tiktok pada Google Playstore dengan SVM menghasilkan nilai akurasi 90,62%. Kajian terhadap dataset Tweeter terkait wabah COVID-19 (Sujadi, 2022) menghasilkan nilai akurasi metode Naïve Bayes 78,63% dan SVM 81,6%. Kajian (Pamungkas and Kharisudin, 2021) terhadap opini terkait COVID-19 di Twitter menghasilkan nilai akurasi SVM Linear 90,01%, NB 72,20% dengan nilai Laplace = 1. Analisis sentimen terhadap ujian kebencian di Twitter oleh (Liang, 2021) menghasilkan nilai akurasi SVM 83,2%, XGBoots 79,6%, dan Neural Network (NN) 82,9%.

Penelitian menggunakan dataset Google Playstore yang dilakukan oleh (Rahman, Utami and Sudarmawan, 2021) menganalisis sentimen ulasan Shopee, Ruangguru, Tokopedia dan Gojek dengan Naïve Bayes dan Algoritma Genetika menghasilkan nilai akurasi pada masing-masing aplikasi yaitu Shopee dengan nilai akurasi 96,53%, Ruangguru dengan nilai akurasi 95,54%, Tokopedia dengan nilai akurasi 96,87% dan Gojek dengan nilai akurasi 96,54%.

Kajian (Iriananda, Putra and Nugroho, 2021) yang menganalisis sentimen aplikasi marketplace yaitu Shopee, Tokopedia dan Lazada, menghasilkan Nilai akurasi optimum pada Decision Tree (DT) dan Random Forest (RF) dalam proses pelatihan adalah 96,55%. Namun dalam kajian ini masih terdapat kekurangan yaitu pada proses pengujian dimana SVM-RBF, dan RF menghasilkan tingkat akurasi 60,08% dalam proses pengujian. Penelitian pada Twitter, Instagram dan Facebook dengan dataset Bahasa Indonesia (Thenata, 2021) menghasilkan Nilai akurasi untuk KNN adalah 50%, dan SVM 98,13%. Sedangkan NB 88%.

Berdasarkan beberapa penelitian tersebut menunjukkan bahwa algoritma SVM memiliki akurasi yang optimal, sehingga penulis tertarik untuk menggunakan algoritma SVM untuk menganalisa sentiment terhadap tiga *mobile game* terpopuler di *Google Playstore*. Kebutuhan untuk mendapat hasil yang optimal menjadi sangat penting, maka dalam penelitian ini penulis menggunakan teknik *Grid Search* (GS) untuk mendapatkan *hyperparameter* yang tepat untuk Algoritma SVM dalam proses *model selection* dengan seleksi fitur menggunakan kombinasi N-Gram diharapkan dapat menghasilkan nilai akurasi yang optimal.

Beberapa skenario dilakukan dalam rangka menginvestigasi metode yang digunakan dalam penelitian ini terhadap akurasi SVM. Kemudian dilakukan evaluasi terhadap model klasifikasi secara menyeluruh menggunakan Akurasi (Acc), *Precision* (Prec), *Recall* (Rec), dan Area dibawah kurva ROC (AUC). Kontribusi kebaruan dalam penelitian ini

dibandingkan dengan penelitian terkait sebelumnya adalah *model classifier* yang terdiri dari kombinasi algoritma Support Vector Machine (SVM), *Grid Search Cross Validation* (GS) dan Kombinasi N-Gram yaitu Unigram + Bigram + Trigram (UniBiTri).

## 2. METODE

Penelitian ini dilakukan pada situs Google Play Store terhadap komentar pengguna game bergerak (*mobile game*) terbaik, sebagaimana yang diidentifikasi melalui pengamatan data. Data ulasan tersebut mencakup informasi mengenai nama pengguna, tanggal pembuatan ulasan, penilaian (*rating*) dalam bentuk bintang yang diberikan oleh pengguna, dan isi (*content*) dari ulasan tersebut. Secara keseluruhan, sistem ini dimulai dengan proses masukan (*input*) berupa data ulasan atau review dari pengguna game populer di Google Play Store berdasarkan observasi data yang dilakukan.

Pada tahap input, dijelaskan data apa yang digunakan dalam proses tersebut. Pada bagian proses sistem, dijelaskan langkah-langkah yang dilakukan mulai dari *preprocessing*, fitur yang digunakan, hingga proses klasifikasi. Tahap output mencakup hasil dari proses yang dapat menghasilkan nilai akhir, termasuk nilai akurasi yang terhitung.

### 2.1 Dataset

Dalam penelitian ini dilakukan observasi data melalui situs web *data.ai* untuk beberapa game *mobile*, dengan tujuan agar data yang dikumpulkan relevan dengan lingkup kajian. Peneliti memilih *mobile game* populer yang memenuhi kriteria pendapatan tertinggi dan jumlah unduhan terbanyak di Google Play Store, dapat diunduh secara gratis, dan kompatibel dengan perangkat Android, khususnya dalam kategori *Game*. Tiga game *mobile* terpilih adalah *Mobile Legends: Bang Bang* (MLBB), *Garena Free Fire Max* (GFFM), dan *Higgs Domino Island* (HDI).

Pengumpulan data selanjutnya dilakukan dengan menggunakan teknik *web scraping*, menghasilkan dataset awal dengan total 7200 baris data. Setiap dataset game terdiri dari 2400 baris data ulasan. Dalam setiap dataset, terdapat 1200 baris data dengan label "positif" dan 1200 baris ulasan dengan label "negatif". Data yang diambil untuk penelitian ini terfokus pada dua kolom, yaitu *Content* (isi ulasan) dan *Score* (skor). *Content* merupakan elemen kunci dalam penelitian ini, merepresentasikan komentar atau ulasan dari pengguna. Skor 1 dan 2 direpresentasikan sebagai label "Positif", sementara skor 4 dan 5 direpresentasikan sebagai label "Negatif".

### 2.2 Preprocessing Teks

Proses *preprocessing* teks sangat dibutuhkan pada setiap tugas analisis sentiment. Pada teks review di Google Playstore sangat sering ditemukan kata, frase atau istilah yang tidak konsisten, tidak baku,



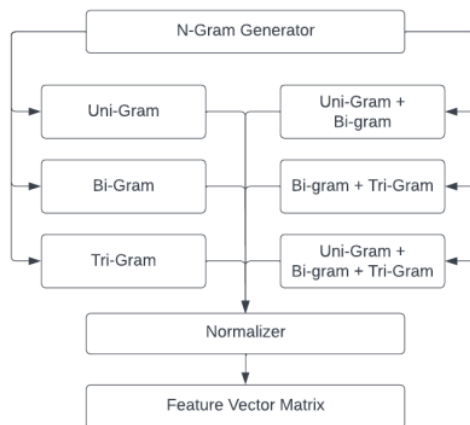
penggunaan bahasa gaul/alay (*slang*), reduksi kata, sehingga perlu melakukan data *preprocessing* sebelum melakukan klasifikasi sentiment (Fide, Suparti and Sudarno, 2021). Tahap ini memerlukan banyak waktu dan sumber daya. Proses ini melakukan generalisasi data, filterisasi, normalisasi, konstruksi, dan transformasi data. Hal ini juga diperlukan untuk menangani ketidakseimbangan (*imbalanced*), karena kelas yang tidak seimbang akan menyebabkan nilai akurasi dari proses klasifikasi yang tidak tepat (Kusnadi *et al.*, 2021). Dalam penelitian ini dilakukan proses Tokenisasi, Case Folding, Filter Teks, Stopword Removal, dan Stemming.

### 2.3 Ekstraksi Fitur (TF-IDF)

Ekstraksi fitur dalam penelitian ini menggunakan Teknik TF-IDF. Data komentar yang telah selesai melalui proses *preprocessing* akan dilakukan proses TF-IDF. setiap kata atau term yang sudah melalui tahap *preprocessing* akan diberi bobot urut berdasarkan id. Jika terdapat term yang sama maka jumlah *term frequency* (TF) akan bertambah 1 dan seterusnya. Setelah itu jika tidak proses akan menghitung jumlah komentar lalu dilanjut dengan menghitung N-Term. Setelah dilakukan penghitungan TF-IDF dan menghasilkan hasil pembobotan TF-IDF. Proses ini akan berulang pada tiap term tiap komentar.

### 2.4 Seleksi Fitur N-Gram

Metode seleksi fitur N-Gram adalah sebuah metode yang digunakan untuk mengatur urutan token dalam sebuah dokumen. Dalam konteks ini, token-token ini dapat berupa kata-kata atau frasa-frasa, yang diurutkan dan dikelompokkan untuk membantu analisis teks. Metode ini memungkinkan pemahaman yang lebih baik terhadap struktur dan konteks teks yang sedang dianalisis. Secara garis besar konsep N-Gram disajikan pada Gambar 1.



Gambar 1. Seleksi Fitur dengan Kombinasi N-Gram

Pada konteks komputasi linguistik, token ini biasanya berupa kata-kata, meskipun bisa berupa

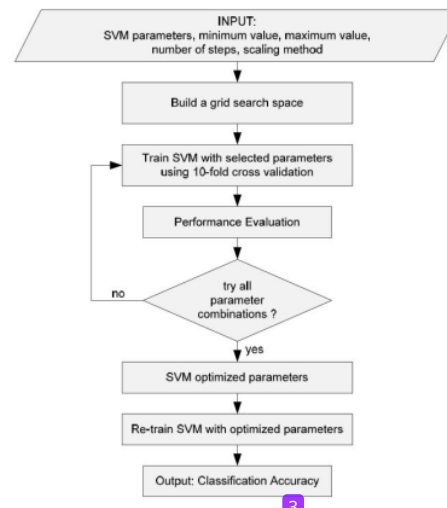
karakter atau himpunan bagian dari karakter. N hanya mengacu pada jumlah token. N-Gram biasanya digunakan untuk menangkap informasi statistik dari beberapa kumpulan data.

Dalam Gambar 1 tersebut menunjukkan gambaran proses untuk mendapatkan nilai TFIDF dengan fitur N-Gram. Dimulai dari input data latih atau data uji yang kemudian diproses oleh library Sklearn Tfidfvectorizer yang merupakan fungsi generator TFIDF dan N-gram dalam sklearn. Dalam library ini kemudian ditentukan jangkauan N-gram pada variabel (*ngram\_range*). Nilai jangkauan dapat berupa angka (1,1) untuk mendapatkan Unigram (Uni), *range* (2,2) untuk mendapatkan Bigram (Bi) dan *range* (3,3) untuk mendapatkan Trigram (Tri).

Kinerja model N-Gram dapat meningkatkan nilai akurasi algoritma klasifikasi (Iriananda *et al.*, 2022). Dalam penelitian ini beberapa kombinasi N-Gram didapatkan dengan menggunakan konfigurasi jangkauan N-Gram yaitu (1,2) untuk mendapatkan Unigram + Bigram (UniBi), *range* (2,3) untuk mendapatkan Bigram + Trigram (BiTri), dan *range* (1,3) untuk Unigram + Bigram + Trigram (UniBiTri). Berdasarkan *range* N-Gram yang sudah ditentukan, kemudian dihitung nilai TFIDF pada setiap *range* N-Gram dan dilakukan normalisasi sehingga membentuk *Feature Vector Matrix* yang kemudian digunakan pada proses selanjutnya.

### 2.5 Grid Search

*Grid Search* adalah pencarian secara menyeluruh berdasarkan subset ruang *hyperparameter* yang ditentukan menggunakan nilai minimal atau batas bawah (*lower bound*), nilai maksimal atau batas atas (*upper bound*), dan jumlah langkah (Khalid and Javaid, 2020). Optimasi parameter SVM menggunakan *grid search* dijelaskan pada Gambar 2.



Gambar 2. Diagram Alir Grid Search

GS menggunakan mekanisme *Cross Validation* dengan kemudahan dalam proses pengujian setiap parameter model tanpa harus melakukan validasi manual satu persatu (Nugraha and Sasongko, 2022). Metode ini digunakan untuk optimasi dalam mencari *hyperparameter* terbaik SVM di sebuah Grid untuk menentukan *hyperparameter* dan konfigurasi yang optimal dengan menggunakan pendekatan estimator terbaik. GS merupakan cara terbaik untuk menentukan parameter dalam pengaturan sebuah algoritma (Radzi *et al.*, 2021), teknik validasi silang (cross-validation) dapat mencegah masalah *over-fitting* (Khalid and Javaid, 2020).

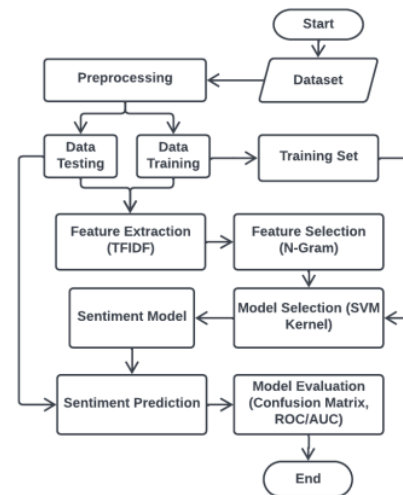
Untuk memilih C dan Gamma menggunakan *k-fold Cross-Validation (CV)*, Langkah pertama adalah membagi data yang tersedia menjadi bagian himpunan k (di sebagian besar eksperimen, kami menetapkan k=10). Satu subset digunakan sebagai data pengujian dan kemudian dievaluasi menggunakan subset pelatihan k-1 yang tersisa. Kemudian kami menghitung kesalahan CV menggunakan kesalahan split ini untuk pengklasifikasi SVM menggunakan nilai C, Gamma, dan parameter lainnya yang berbeda. Akhirnya, berbagai kombinasi nilai *hyperparameter* dimasukkan. Dengan akurasi validasi silang terbaik (atau kesalahan CV terendah) dipilih dan digunakan untuk melatih SVM di seluruh kumpulan data.

Dalam proses Grid Search yang disajikan pada Gambar 2 tersebut, rentang minimum dan maksimum *hyperparameter*, jumlah cross-validation (CV), dan metode klasifikasi menjadi inisialisasi input. Kemudian diproses dalam ruang *grid search*. Klasifikasi dilakukan dengan melatih dan menguji data sebanyak 10 kali. Dari proses tersebut dievaluasi sampai memiliki nilai akurasi optimum. Dalam pengujian ini, kami menggunakan rentang parameter C dan Gamma mulai dari 0,001 hingga 100 (0.001, 0.01, 0.1, 1, 10, 100, 100). Dengan *estimator* kernel dalam pengujian GS adalah Linear, Polynomial, RBF dan Sigmoid.

## 2.6 Model Klasifikasi

Secara global model klasifikasi disajikan pada Gambar 3. Proses diawali dengan masukan (input) berupa dataset ulasan pengguna game online populer pada Google Play Store. Kemudian proses *preprocessing* teks yang hasilnya dibagi menjadi dua bagian, yaitu data *Training*, dan data *Testing*.

Proses Selanjutnya adalah Ekstraksi Fitur dengan pembobotan kata menggunakan metode *TFIDF* (*Term Frequency Inverse Document Frequency*). Setelah dilakukan serangkaian perhitungan bobot setiap kata, kemudian dipilih fitur terbaik dengan N-Gram, yaitu Unigram (Uni), Bigram (Bi), atau Trigram (Tri) dan kombinasi Unigram + Bigram (UniBi), Bigram + Trigram (BiTri), dan Unigram + Bigram + Trigram (UniBiTri).



Gambar 3. Model Klasifikasi Sentimen

Merujuk pada Gambar 3. Tersebut, Hasil TFIDF dan N-Gram selanjutnya digunakan pada proses seleksi model dengan memanfaatkan data *Training* yang sebelumnya telah ditentukan. Dalam penelitian ini proses *Model Selection* menggunakan metode *Grid Search (GS)* guna mendapatkan model klasifikasi yang optimal dengan cara melakukan pencarian terhadap *hyperparameter*.

Dalam proses ini juga dapat aplikasikan untuk pencarian jangkauan N-Gram (*n-gram range*) dan batasan maksimal fitur (*max feature*) yang optimal pada setiap prosesnya. Proses *Sentiment Prediction* memanfaatkan data *Testing* yang telah ditentukan dan dibagi dari proses sebelumnya. Prediksi sentimen ini menggunakan model SVM yang optimal pada proses sebelumnya, sehingga didapatkan nilai akurasi, precision, recall dan ROC/AUC yang optimal pada proses evaluasi.

## 3. HASIL DAN PEMBAHASAN

Dalam penelitian ini, dilakukan eksperimen dengan tiga skenario, yaitu Grid Search, N-Gram, dan variasi jumlah baris data. Pada skenario Grid Search, eksperimen dilakukan dengan menggunakan gabungan seluruh dataset dari Mobile Legends: Bang Bang (MLBB), Garena Free Fire Max (GFFM), dan Higgs Domino Island (HDI). Jumlah sampel dalam dataset sebanyak 3600 baris data, dengan rasio perbandingan data latih dan data uji adalah 75:25, artinya 75% data digunakan sebagai data latih dan 25% sebagai data uji. Selain itu, Feature Selection (FS) dilakukan dengan menggunakan Unigram + Bigram + Trigram (UniBiTri).

Peramalan klasifikasi menggunakan Estimator SVC pada kernel SVM melibatkan empat kernel, yaitu Linear, Polynomial, RBF, dan Sigmoid, dengan penggunaan cross-validation sebanyak 10 kali (cv =

10). Pengujian dilakukan untuk mencari parameter C (complexity) dan Gamma ( $\gamma$ ) dengan jangkauan nilai (0.001, 0.01, 0.1, 1, 10, 100). Model kernel yang paling optimum diidentifikasi dengan menerapkan Teknik Grid Search (GS), dengan jumlah kombinasi optimum GS (Fit) sebanyak  $6 \times 6 \times 4 \times 10 = 1440$  kombinasi.


Meskipun terdapat 1440 kombinasi yang mungkin, dalam kajian ini, penulis hanya memperlihatkan lima kombinasi terbaik yang memberikan nilai evaluasi optimal. Kelima kombinasi ini mencerminkan gambaran nilai optimum dari keseluruhan 1440 kombinasi yang dihasilkan dalam proses Grid Search. Presentasi hasil dilakukan pada Tabel 2, yang memuat informasi tentang lima hasil paling optimum dari proses GS (Fit).

Tabel 2. Evaluasi Skenario Grid Search

C	Gamma	Kernel	Acc. (%)	Prec. (%)	Rec. (%)
1	$\gamma$ 1	RBF	<b>86.56</b>	<b>86.62</b>	<b>86.56</b>
100	$\gamma$ 1	RBF	86.56	86.59	86.56
10	$\gamma$ 1	RBF	86.48	86.53	86.48
100	$\gamma$ 0.1	RBF	84.85	84.90	84.85
10	$\gamma$ 0.1	RBF	84.67	84.72	84.67

Berdasarkan hasil tersebut, dapat dilihat bahwa nilai akurasi optimum diperoleh dengan parameter Gamma = 1, C = 1, dan C = 100, menggunakan kernel RBF, mencapai 86,56%. Selain itu, terdapat nilai precision sebesar 86,62% dan nilai recall sebesar 86,56%. Menariknya, dalam hasil tersebut, nilai C = 1 dan C = 100 memberikan akurasi yang sama. Namun, dalam pertimbangan penulis, nilai precision juga menjadi faktor yang diperhitungkan.

Hasil Grid Search merekomendasikan kombinasi parameter Gamma = 1, C = 1, dengan kernel RBF sebagai nilai yang paling optimum, mengingat nilai precision yang optimal. Sebagai ilustrasi, penulis menyajikan visualisasi dalam bentuk grafik pada Gambar 4



Gambar 4. Grafik Nilai Akurasi Skenario Grid Search


Pada pengujian skenario N-Gram, kami menggunakan 3600 baris data dari dataset gabungan (Allgame) dengan rasio perbandingan data latih dan data uji sebesar 75:25. Pengujian dilakukan dengan menerapkan Feature Selection (FS) menggunakan variasi Unigram (Uni), Unigram + Bigram (UniBi), Unigram + Bigram + Trigram (UniBiTri), Bigram

(Bi), Bigram + Trigram (BiTri), dan Trigram (Tri). Nilai Gamma ( $\gamma$ ) tetap pada Gamma = 1, sementara nilai C (complexity) diatur pada C = 1, dengan penggunaan cross-validation sebesar cv = 10. Hasil akurasi dari skenario N-Gram dapat dilihat pada Tabel 3.

Tabel 3. Nilai Akurasi Pada Skenario N-Gram (dalam %)

N-Gram	Linear	RBF	Polynomial	Sigmoid
Uni	83.90	86.90	85.10	76.00
UniBi	85.60	86.90	84.90	79.90
UniBiTri	84.80	<b>87.33</b>	84.70	75.30
Bi	78.60	80.70	80.00	77.60
BiTri	78.20	79.00	78.90	75.90
Tri	65.20	65.70	65.40	65.20

Berdasarkan hasil pengujian pada tabel 3 tersebut dapat dilihat bahwa nilai akurasi maksimum didapatkan dengan fitur seleksi Unigram + Bigram + Trigram (UniBiTri) dengan menggunakan kernel RBF yaitu 87,33%. Dalam pengujian ini dapat dilihat bahwa kernel RBF selalu mendapatkan nilai akurasi tertinggi dibandingkan dengan kernel yang lainnya. Nilai akurasi minimum didapatkan dari seleksi fitur Trigram (Tri) yaitu 65,22% dengan kernel Linear dan Sigmoid. Secara visual hasil tabel 3 direpresentasikan pada Gambar 5 berikut:



Gambar 5. Nilai Akurasi Fitur Seleksi N-Gram

Dari grafik pada Gambar 5, terlihat bahwa fitur seleksi Bigram (Bi), Bigram + Trigram (BiTri), dan Trigram (3,3) secara rata-rata memiliki angka akurasi yang lebih rendah dibandingkan dengan seleksi fitur yang melibatkan Unigram di dalamnya. Namun, perlu dicatat bahwa pada kernel Sigmoid, nilai akurasi fitur seleksi Bigram (Bi) justru lebih baik daripada Unigram (Uni).

Investigasi selanjutnya dilakukan dengan melakukan eksperimen pada skenario jumlah baris data. Pengujian dilakukan dengan menggunakan gabungan seluruh dataset (Allgame), dengan jumlah baris data sebanyak 1200, 2400, dan 3600. Rasio perbandingan data latih dan data uji tetap 75:25, yang berarti 75% data digunakan sebagai data latih dan 25% sebagai data uji. Fitur Selection (FS) N-Gram menggunakan fitur seleksi N-Gram UniBiTri. Nilai




Gamma ( $\gamma$ ) adalah 1 untuk seluruh dataset. Nilai C (complexity) adalah 1 pada jumlah baris dataset 1200 dan 2400. Sedangkan, untuk baris data 3600, nilai C (complexity) adalah 10, berdasarkan rekomendasi hasil pencarian grid (GS) yang telah dilakukan. Sampel dipilih secara acak dan seimbang dengan nilai random\_state adalah 4212 dan dilakukan secara bertingkat (*stratified*). Kernel yang digunakan melibatkan Linear, Polynomial, Radial Basis Function (RBF), dan Sigmoid. Hasil pengujian skenario berdasarkan jumlah baris dataset dapat dilihat pada Tabel 4 berikut.

**Tabel 4.** Nilai Akurasi Skenario Jumlah Baris Data (dalam %)

Jumlah Baris	Linear	RBF	Polynomial	Sigmoid
1200	77.70	76.00	69.70	76.30
2400	80.50	83.80	80.20	79.50
3600	84.77	<b>87.33</b>	84.70	75.30

Berdasarkan hasil pengujian pada Tabel 4 di atas, terlihat bahwa nilai akurasi maksimum adalah 87,33%, dihasilkan dari dataset Allgame (3600) dengan ukuran baris data sebanyak 3600. Penggunaan kernel RBF pada dataset Allgame (3600) memberikan hasil akurasi tertinggi. Sebaliknya, nilai akurasi paling rendah adalah 69,7%, dihasilkan dari dataset Allgame (1200) dengan ukuran baris data sebanyak 1200, menggunakan kernel Polynomial.

Hasil pengujian dengan skenario jumlah dataset pada tabel tersebut kemudian digunakan untuk membuat grafik visualisasi, yang secara visual merepresentasikan hasil pengujian menggunakan dataset gabungan dengan skenario 5 mlah baris data 1200, 2400, dan 3600. Grafik ini dapat dilihat pada Gambar 6.



**Gambar 6.** Grafik Nilai Akurasi Skenario

Gambar ini memberikan gambaran visual atas hasil pengujian dengan menggunakan dataset gabungan pada tiga skenario jumlah baris data tersebut. Visualisasi yang disajikan pada Gambar 6 merepresentasikan nilai akurasi dari setiap pengujian dengan skenario jumlah baris data pada dataset gabungan. Grafik tersebut menunjukkan bahwa semakin banyak jumlah baris data, nilai akurasi cenderung meningkat. Fenomena ini terlihat pada kernel Linear, Polynomial, dan RBF. Namun, terjadi kebalikan pada kernel Sigmoid.

Nilai akurasi optimum diperoleh dari pengujian dengan jumlah baris data sebanyak 3600 pada kernel RBF (3600), menghasilkan nilai akurasi sebesar 87,3%. Pada kasus kernel RBF (2400), nilai akurasi mencapai 83,8%, sementara kernel Linear (1200) memiliki nilai akurasi tertinggi, yaitu 76%. Dari grafik tersebut juga dapat diperhatikan bahwa dengan penambahan jumlah baris data menjadi 3600, rata-rata nilai akurasi meningkat untuk seluruh kernel jika dibandingkan dengan jumlah baris data 1200 dan 2400. Nilai akurasi pada kernel RBF (3600) memiliki selisih 0,5% dibandingkan dengan kernel RBF (2400).

Hasil yang menarik perhatian terjadi pada kernel RBF (1200) dengan nilai akurasi sebesar 76,0%. Hasil ini menunjukkan penurunan sebesar 1,7% dibandingkan dengan kernel Linear (1200) yang mencapai 77,7%, dan 0,3% lebih rendah daripada kernel Sigmoid (1200) yang mencapai 76,3%. Selain itu, secara umum, skenario dengan jumlah baris data 1200 memiliki nilai akurasi yang cenderung lebih rendah dibandingkan dengan skenario 2400 dan 3600. Terdapat satu pengecualian pada skenario dengan kernel Sigmoid (2400), yang memiliki nilai akurasi sebesar 79,5%, lebih unggul sebesar 4,2% dibandingkan dengan Sigmoid (3600) yang mencapai 79,3%. Selain itu, nilai akurasi pada kernel Sigmoid (1200) juga lebih baik 0,3% daripada RBF (1200).

Berdasarkan hasil eksperimen yang telah dilakukan, tampaknya jumlah baris data pada pengujian berpengaruh pada hasil akurasi Algoritma SVM. Pada tahap selanjutnya, evaluasi dilakukan secara menyeluruh terhadap model klasifikasi SVM dengan menggunakan hyperparameter  $C = 1$  dan  $\text{Gamma} = 1$  pada 3600 data dari dataset 25 game. Hasil evaluasi model klasifikasi sentiment disajikan pada Tabel 5 berikut

**Tabel 5.** Evaluasi Model Klasifikasi Sentimen


Kernel	Acc.	Prec.	Recall	AUC
Linear	84.78%	81.78%	87.00%	0.8968
RBF	<b>87.33%</b>	<b>85.78%</b>	88.53%	0.9081
Polynomial	84.67%	77.11%	<b>90.84%</b>	<b>0.9193</b>
Sigmoid	75.33%	70.89%	77.80%	0.7565

Eksperimen ini melibatkan fitur seleksi UniBiTri, dengan batasan maksimum fitur sebanyak 3000 fitur. Kernel yang digunakan mencakup Linear, RBF, Polynomial, dan Sigmoid.

Berdasarkan eksperimen yang dilakukan, hasil evaluasi pada Tabel 5 menunjukkan bahwa Kernel RBF memberikan hasil yang optimal, dengan nilai akurasi tertinggi sebesar 87,33%, Precision 85,78%, Recall 88,53%, dan nilai AUC 0.9081. Selanjutnya, Kernel Linear mencapai akurasi sebesar 84,78%, Precision 81,78%, Recall 87,00%, dan nilai AUC 0.8968. Pada Kernel Polynomial, nilai akurasi dan Precision lebih rendah dibandingkan dengan Kernel Linear dan RBF. Meskipun demikian, nilai Recall dan AUC pada Kernel Polynomial lebih tinggi dari semua kernel lainnya, yaitu Recall sebesar 90,84%, dan



AUC mencapai 0.9193. Hasil evaluasi divisualisasikan dalam bentuk area dibawah kurva pada Gambar 7 berikut



Gambar 7 Nilai AUC Klasifikasi Sentimen

Berdasarkan eksperimen, dapat dilihat dari Gambar 7 bahwa Kernel RBF menunjukkan hasil akurasi yang paling optimal, mencapai 87,33%, dibandingkan dengan Kernel Linear (84,48%), Kernel Polynomial (84,67%), dan nilai terendah ada Sigmoid (75,3%). Meskipun demikian, ketika dilihat dari nilai AUC, Kernel Polynomial menunjukkan kinerja yang lebih baik dengan nilai AUC sebesar 0,919, melebihi Kernel RBF yang memiliki nilai AUC sebesar 0,908 dengan selisih 0,0112 poin. Hal ini mengindikasikan bahwa kinerja Algoritma klasifikasi dengan menggunakan Kernel Polynomial lebih unggul daripada RBF. Namun, perlu dicatat bahwa penelitian ini belum dapat memberikan kepastian mengenai penyebab perbedaan tersebut, sehingga memerlukan investigasi lebih lanjut pada penelitian selanjutnya.

#### 4. KESIMPULAN

Melalui hasil analisis dan pengujian yang telah diuraikan pada bab sebelumnya, dapat diambil beberapa kesimpulan dalam kajian ini bahwa Algoritma SVM dapat berhasil diterapkan untuk tugas analisis sentimen pada teks ulasan pengguna mobile game online populer di Google Play Store. Nilai akurasi optimum pada pengujian skenario dataset ini dicapai dengan menggunakan 3600 baris data pada dataset gabungan (allgame), mencapai 87,33%. Hasil ini menunjukkan peningkatan sebesar 17,33% dari penelitian sebelumnya (Arifin, Enri and Sulistiyowati, 2021), yang memiliki nilai akurasi maksimum sebesar 70%.

Nilai akurasi sebesar 87,33% dapat dicapai dengan mengadopsi rasio data latih dan data uji sebesar 75:25. Proses model selection yang melibatkan algoritma Grid Search dan Cross-Validation dengan  $cv = 10$  terbukti dapat meningkatkan kinerja algoritma SVM. Pemilihan hyperparameter dengan menggunakan algoritma Grid Search dan Cross-Validation, dengan  $cv = 10$ , menghasilkan parameter terbaik, yaitu  $C$  (complexity) = 1 dan  $\Gamma$  (gamma) = 1, pada algoritma

SVM. Hal ini membuktikan bahwa pemilihan parameter yang tepat dapat menghasilkan nilai akurasi yang optimal. Dalam konteks penelitian ini, nilai akurasi tertinggi mencapai 86,56%, dengan nilai recall 86,56%, nilai precision 81,62%, dan f-measure 86,55%, yang dicapai melalui pemilihan kernel yang tepat, yaitu kernel Radial Basis Function (RBF).

Penting juga untuk mencatat bahwa pemilihan jenis feature selection, seperti N-Gram, memiliki peran yang signifikan dalam meningkatkan nilai akurasi algoritma klasifikasi. Dalam penelitian ini, penggunaan feature selection N-Gram berhasil meningkatkan performa algoritma dengan menghasilkan nilai akurasi sebesar 87,33%.

Penelitian ini mengadopsi fitur selection kombinasi N-gram, khususnya Unigram + Bigram + TriGram (UniBiTri), dengan jumlah fitur maksimal yang ditetapkan sebanyak 3000. Berdasarkan hasil yang telah dijelaskan di atas, dapat dilihat bahwa semakin banyak jumlah dataset, semakin tinggi pula tingkat cross-validation, dan semakin banyak parameter yang digunakan dalam proses penyetalan melalui Grid Search (GS), maka semakin besar pula penggunaan sumber daya memory dan waktu yang diperlukan dalam proses tersebut.

#### 5. DAFTAR PUSTAKA

8244

ORIGINALITY REPORT

22%

SIMILARITY INDEX

21%

INTERNET SOURCES

5%

PUBLICATIONS

3%

STUDENT PAPERS

PRIMARY SOURCES

1

[publishing-widyagama.ac.id](http://publishing-widyagama.ac.id)

Internet Source

12%

2

Submitted to Universitas Brawijaya

Student Paper

2%

3

[sistemasi.ftik.unisi.ac.id](http://sistemasi.ftik.unisi.ac.id)

Internet Source

1%

4

[journal.unimma.ac.id](http://journal.unimma.ac.id)

Internet Source

1%

5

[id.123dok.com](http://id.123dok.com)

Internet Source

1%

6

[doaj.org](http://doaj.org)

Internet Source

1%

7

[openjournal.unpam.ac.id](http://openjournal.unpam.ac.id)

Internet Source

<1%

8

[www.researchgate.net](http://www.researchgate.net)

Internet Source

<1%

9

[repository.uin-suska.ac.id](http://repository.uin-suska.ac.id)

Internet Source

<1%

10	Submitted to iGroup Student Paper	<1 %
11	jtiik.ub.ac.id Internet Source	<1 %
12	ojs.serambimekkah.ac.id Internet Source	<1 %
13	docplayer.info Internet Source	<1 %
14	pt.scribd.com Internet Source	<1 %
15	Rahmah Safitri Meutia, Sally Aman Nasution, Lukman H Makmun, Esthika Dewiasty. "Uji Validasi Simple Risk Index dan Evaluation of Methods and Management of Acute Coronary Events dalam Memprediksi Mortalitas Pasien Sindrom Koroner Akut di Intensive Coronary Care Unit Rumah Sakit Cipto Mangunkusumo", Jurnal Penyakit Dalam Indonesia, 2017 Publication	<1 %
16	conference.upnvj.ac.id Internet Source	<1 %
17	docobook.com Internet Source	<1 %
18	knastik.ukdw.ac.id Internet Source	<1 %

19	<a href="http://lawangtech.com">lawangtech.com</a> Internet Source	<1 %
20	Fitri Ella Fauziah. "Diversitas Gender dan Nilai Perusahaan dengan Corporate Social Responsibility sebagai Variabel Intervening", Media Ekonomi dan Manajemen, 2018 Publication	<1 %
21	Siti Khotimatul Wildah, Sarifah Agustiani, M. Rangga Ramadhan S, Windu Gata, Hendri Mahmud Nawawi. "DETEKSI PENYAKIT ALZHEIMER MENGGUNAKAN ALGORITMA NAÏVE BAYES DAN CORRELATION BASED FEATURE SELECTION", Jurnal Informatika, 2020 Publication	<1 %
22	<a href="http://beei.org">beei.org</a> Internet Source	<1 %
23	<a href="http://core.ac.uk">core.ac.uk</a> Internet Source	<1 %
24	<a href="http://ejournal.stkipjb.ac.id">ejournal.stkipjb.ac.id</a> Internet Source	<1 %
25	<a href="http://id.scribd.com">id.scribd.com</a> Internet Source	<1 %
26	<a href="http://repository.uinjkt.ac.id">repository.uinjkt.ac.id</a> Internet Source	<1 %



---

Exclude quotes      Off

Exclude matches      Off

Exclude bibliography      Off